Classification du genre (mouvement) d'oeuvres d'arts

Sebastian Caron Lina Lethoor Gregory Duporge Julien Biout

2 Novembre 2026

Ce projet consiste à classifier le style artistique d'oeuvres d'art à travers leurs représentations latentes, intégrant un serveur MCP (Model Context Protocol).

Le modèle final peut classifier les oeuvres d'art dans 21 mouvements artistiques majeurs (Renaissance, Baroque, Impressionnisme, Cubisme, etc.) et extraire des embeddings pour la recherche d'analogies visuelles.

I. Installation

1. Installation de l'environnement

Prérequis

- Python 3.10+ (testé avec Python 3.12 / 3.14)
- Carte graphique NVIDIA recommandée avec pilotes CUDA à jour

Création du venv

```
# Cloner le dépôt et se placer dans le projet
cd project

# Créer et activer l'environnement virtuel
python3 -m venv .venv
source .venv/bin/activate
```

Installation des dépendances

```
# Dépendances de base (PyTorch, Torchvision, Pillow)
pip install -r requirements.txt

# Si vous disposez d'un GPU NVIDIA (CUDA 12.1+), installez la version GPU de
↪ PyTorch :
# pip install torch torchvision --index-url
↪ https://download.pytorch.org/whl/cu121

# Dépendances pour le serveur MCP et les outils d'indexation
pip install "mcp>=2.3.0" tqdm
```

---

2. Téléchargement & Préparation du dataset (ART500K)

Le projet utilise le dataset **ART500K** (~500 000 images d'oeuvres d'art et leurs métadonnées).

> **Note :** Choisissez "Raw images of visual arts with general label list: Data&Labels(56.6GB)/Labels".

Structure attendue dans `data/`

Après extraction, le dossier `data/` doit avoir l'arborescence suivante :

```
data/
├── Art Movement/   # 119 dossiers de mouvements
├── Artists1/       # Oeuvres par artistes (partie 1)
├── Artists2/       # Oeuvres par artistes (partie 2)
├── Medium/         # Oeuvres classées par support
├── label_list.csv  # Table de métadonnées
├── head_info.csv   # En-têtes des métadonnées
└── Readme
```

Extraction de l'archive

Si vous disposez de l'archive `art500k.tar.gz` (téléchargement ou support externe) :

```
mkdir -p data
tar -xzf art500k.tar.gz -C data/
```

> **Note :** Le chargeur de données (`src/loader.py`) filtre et associe automatiquement les sous-dossiers de `data/Art Movement/` aux 21 classes canoniques sans conflit d'étiquetage.

> **Note encore :** Nous n'utilisons pas le dossier Artists1 car il n'y a quasiment pas d'informations sur le genre. Nous aurions pu cependant intégrer Artists2 mais cela ajoute des problèmatiques d'équilibrage et représentation des classes, en plus d'allonger le temps d'entrainement. Nous nous reservons le droit d'intégrer les données, de poursuivre l'entrainement et d'améliorer les models pour la V2.

II. Méthodologie

1. Structure du projet

Le projet est conçu de façon modulaire afin de découpler la préparation des données, l'entraînement des modèles, l'analyse expérimentale et l'interfaçage avec un agent conversationnel via le protocole MCP (*Model Context Protocol*).

```
project/
├── data/           # Données brutes ART500K
├── checkpoints/    # Poids et checkpoints
│   ├── gallery_index.pt # Embeddings 512D
│   └── ArtClassifier/ # Modèles entraînés
├── rapports/       # Rapports et figures
├── src/            # Code source modulaire
│   ├── models/     # CustomArtCNN, ConvNeXt
│   ├── serv_mcp/   # Serveur MCP et outils LLM
│   ├── loader.py   # Dataset et taxonomie
```

```
|   ├── early_stopping.py # Arrêt anticipé
|   ├── trainer.py  # Entraînement AMP fp16
|   └── measures.py # Métriques complètes
├── requirements.txt # Dépendances
└── README.md       # Guide d'exécution
```

Rôles des principaux composants logiciels

1. **`src/loader.py`** :
   - Effectue la résolution et le regroupement des 119 dossiers initiaux en **21 classes** mutuellement exclusives via le dictionnaire `TAXONOMY_MAPPING`.
   - Construit les pipelines de transformation avec `torchvision.transforms.v2` (augmentations riches en entraînement, redimensionnement bicubique et recadrage centré).
2. **`src/models/`** :
   - `CustomArtCNN` : CNN classique à 4 blocs convolutionnels avec normalisation par lots, servant de baseline entraînée à partir de zéro (*from scratch*).
   - `ArtClassifier` : Modèle s'appuyant sur un backbone `resnet50` pré-entraîné, projeté dans un espace latent à 512 dimensions avant la tête de classification.
   - `ArtClassifierTinyBased` : Modèle de production s'appuyant sur un backbone `convnext_tiny` pré-entraîné, projeté dans un espace latent à 512 dimensions avant la tête de classification.
3. **`src/serv_mcp/`** :
   - Implémente le protocole MCP (*Model Context Protocol*) permettant à des LLM (comme Claude, Antigravity ou Gemini) d'invoquer le modèle de vision en tant qu'outil outillé (*tool use*).
4. **`src/trainer.py`** & **`src/early_stopping.py`** :
   -

Assurent un entraînement robuste avec précision mixte AMP (`torch.autocast(fp16)`), suivi en temps réel de la loss et des métriques Micro/Macro Top-1 et Top-5, ainsi que l'arrêt anticipé avec restauration automatique du meilleur checkpoint.

2. Implémentation du serveur MCP

L'implémentation du serveur MCP, baptisé `ArtExplorerMCP`, a été conçue selon une architecture modulaire en cinq fichiers distincts afin de séparer la préparation des données, le moteur d'inférence Deep Learning, la logique métier, les fonctions utilitaires et l'exposition protocolaire.

A. Architecture et implémentation technique

Pré-calcul et indexation de la galerie (`build_index.py`) Pour garantir un meilleur temps de réponse lors des requêtes de similarité, on a développé un script d'indexation préalable. Il charge le jeu de validation canonique (21 mouvements artistiques) ainsi que le modèle `ArtClassifierTinyBased` depuis le checkpoint `best_model.pth`.

Chaque oeuvre passe dans le réseau en mode évaluation pour en extraire : * Le vecteur de caractéristiques dans l'espace latent. * La classe prédite et le score de confiance associé.

Ces tenseurs sont enrichis avec les métadonnées (identifiant, chemin local, titre de l'oeuvre, auteur extrait de `label_list.csv`, style réel) puis sérialisés dans un fichier unique `checkpoints/gallery_index.pt`.

Moteur d'inférence et gestion de la mémoire (`mcp_model_interface.py`) L'interfaçage avec PyTorch est encapsulé dans la classe `ModelEngine`, qui implémente le patron de conception **Singleton** (via la méthode de classe `get_instance()`). Ce choix architectural garantit que le modèle ConvNeXt-Tiny, l'index de la galerie (`gallery_index.pt`) et la table des métadonnées ne sont chargés qu'une seule fois en mémoire lors du premier appel d'un outil.

Le moteur gère également le prétraitement des images à la volée : conversion au format `RGB` et application des transformations d'évaluation standardisées (redimensionnement) avant l'extraction conjointe des embeddings latents et des probabilités.

Résolution flexible des entrées et gestion du cache (`utils.py`) Afin de rendre le serveur robuste aux différentes requêtes d'un agent conversationnel, le module utilitaire implémente une fonction de résolution intelligente (`resolve_image`). L'utilisateur ou le LLM peut fournir indifféremment : 1. **Une URL web (`http://` ou `https://`)** : l'image est téléchargée à la volée et mise en cache localement dans `data/cache_mcp` avec un nommage unique basé sur un hachage `MD5` de l'URL afin d'éviter les téléchargements redondants. 2. **Un chemin de fichier local** (absolu ou relatif). 3. **Un simple identifiant ou nom de fichier d'oeuvre** : le système effectue une correspondance directe via un dictionnaire d'indexation (`id_to_gallery_idx`) ou lance une recherche par motif (`glob`) dans l'arborescence locale `data/Art Movement`.

Ce module assure également la réconciliation des métadonnées entre le fichier CSV des labels et la taxonomie des dossiers.

Couche serveur et protocole de communication (`mcp_server.py`)

Le point d'entrée utilise la classe `MCPServer` du SDK MCP. Il expose les fonctions métiers à l'aide du décorateur `@mcp.tool()` et communique avec le client via le transport standard d'entrée/sortie (`stdio`). Cela permet une intégration locale directe et sans latence réseau avec des clients compatibles (comme Claude Desktop ou des IDE).

B. Description des Tools mis à disposition

Quatre outils (*tools*) sont exposés par le serveur dans `mcp_server.py` et implémentés dans `tools.py` :

C. Gestion des Prompts et guidage du LLM

Guidage implicite dans le code Dans l'implémentation actuelle, le guidage sémantique du modèle de langage repose sur deux mécanismes : - **Les docstrings structurées des outils** : Chaque fonction décorée par `@mcp.tool()` possède une documentation détaillée en français précisant le rôle métier, l'interprétation artistique possible et le format des arguments. - **L'enrichissement textuel des sorties** : L'outil `find_cross_style_neighbors` génère automatiquement un champ pré-rédigé (`stylistic_observation`) dans sa réponse JSON (*« Bien qu'étiqueté comme 'X', ce tableau partage Y% de similarité latente avec 'Z'. »*), guidant directement l'interprétation finale de l'assistant.

3. Modèle Spécialiste & Protocole Expérimental

3.1 Architecture du Modèle Spécialiste (`ArtClassifierTinyBased`)

Le modèle sélectionné pour le déploiement est **`ArtClassifierTinyBased`**, implémenté dans `src/models/pretrained.py`.

Il se compose de : 1. **Backbone ConvNeXt-Tiny** : - Modèle convolutionnel moderne incorporant les avancées des Vision Transformers (convolutions séparables en profondeur 7×7, normalisation `LayerNorm`, activations `GELU`, expansion inversée $1 \times 1 \to 7 \times 7 \to 1 \times 1$). - Pré-entraîné sur ImageNet-1K (`ConvNeXt_Tiny_Weights.DEFAULT`), fournissant une extraction robuste de descripteurs visuels de bas et moyen niveau (bords, textures, contrastes, compositions). - Dimension de sortie du pooling adaptatif : **768 dimensions**. 2. **Tête de Projection Latente (Espace d'Embedding)** : - Une couche linéaire dense : $\mathbb{R}^{768} \to \mathbb{R}^{512}$. - Une normalisation par lots `BatchNorm1d(512)`. - Une fonction d'activation non linéaire `GELU()`. - Une couche de régularisation par masquage aléatoire `Dropout(p=0.4)`. 3. **Tête de Classification** : - Une couche linéaire finale : $\mathbb{R}^{512} \to \mathbb{R}^{21}$ projetant l'embedding vers les scores de vraisemblance des 21 mouvements artistiques. - Initialisation de Kaiming normale (`kaiming_normal_`) sur les poids de la projection et du classifieur avec biais initialisés à zéro.

3.2 Justification des Hyperparamètres

Le choix des hyperparamètres a été guidé à la fois par la théorie en computer vision et par les contraintes matérielles réelles de notre banc d'essai (GPU NVIDIA RTX 3050 Laptop / 4 Go de VRAM).

3.3 Choix des Classes & Canonisation Taxonomique

Le jeu de données brut **ART500K** organise initialement ses dossiers en plus de 117 sous-dossiers très fragmentés, présentant des redondances lexicales et historiques majeures : - Des subdivisions d'un même courant : *Florentine painting*, *Venetian school*, *Bolognese School*, *Northern Renaissance* coexistaient avec *Renaissance*. - Des catégories génériques englobantes : *Modern art* et *Modernism*. - Des dénominations doublons : *Social realism* et *Socialist realism*.

Ces subdivisions peuvent entrainer des confusions lors de la prédiction de la classe d'une oeuvre d'art. Les mouvements se ressemblent trop.

Pour remédier à ces confusions, nous avons mis en place une table de correspondance (`TAXONOMY_MAPPING` dans `src/loader.py`) regroupant l'ensemble des œuvres en **21 mouvements artistiques majeurs et cohérents**.

Validation empirique : Comparaison des matrices de confusion Pour attester rigoureusement de la pertinence de ce regroupement, deux modèles identiques ont été entraînés et évalués sur la totalité de leurs classes respectives *(les représentations graphiques haute résolution des deux matrices sont détaillées en Annexe A)* :

1. **Modèle Canonique (21 classes)** — Figure haute résolution :
   - **Micro Top-1 : 81,20%** sur 3 313 images de validation.
   - La diagonale principale est très fortement marquée : *Street Art & Art Public* culmine à **96%**, *Réalisme Social* à **100%**, *Art Japonais* à **90%**, *Expressionnisme* à **91%**, *Impressionnisme* à **84%**.
   - Les quelques confusions résiduelles sont **historiquement et artistiquement fondées** : par exemple, le *Maniérisme* est confondu à 40% avec la *Renaissance* (dont il constitue l'évolution stylistique directe), et le *Rococo* est classé à 15% en *Baroque*.
2. **Modèle Non Canonique (117 classes brutes)** — Figure haute résolution :
   - **Micro Top-1 : 65,67%** sur 4 087 images de validation (chute de **-15,5%**).

Nom de l'outil	Paramètres	Rôle et données retournées
`predict_style`	`image_path_or_id: str`	Réalise la classification stylistique d'une oeuvre. Retourne les métadonnées (titre, artiste, style réel si connu), le style prédit, la confiance, un booléen de validité (`is_correct`), ainsi que le **Top 5** des styles les plus probables.
`find_similar_artworks`	`image_path_or_id: strk: int = 5`	Recherche les k oeuvres les plus ressemblantes dans la galerie en calculant la **similarité cosinus** dans l'espace latent (512 dim.). Exclut l'oeuvre requête si elle est déjà dans la galerie. Retourne les voisins avec leurs métadonnées et leur pourcentage de similarité.
`find_cross_style_neighbors`	`image_path_or_id: strk: int = 5`	Identifie les k oeuvres visuellement les plus proches mais appartenant à un **mouvement artistique différent** (les oeuvres du même style voient leur score pénalisé à -2.0). Permet d'étudier les influences croisées de palette, de lumière ou de composition.
`get_model_info`	*Aucun*	Outil d'introspection retournant les spécifications techniques : architecture (`ConvNeXt-Tiny`), dimension latente (512), périphérique actif (`cuda`/`cpu`), liste des 21 classes canoniques, taille de la galerie et checkpoint utilisé.

Hyperparamètre	Valeur retenue	Justification théorique et expérimentale
Résolution image (`img_size`)	288×288	Supérieure à la résolution standard 224×224. Dans l'analyse artistique, la texture des toiles, la finesse des coups de pinceau et les craquelures requièrent un niveau de détail élevé. Le ratio d'évaluation utilise un redimensionnement bicubique à 329 pixels suivi d'un `CenterCrop(288)`.
Optimiseur	Adam	Permet un calcul de taux d'apprentissage adaptatif par paramètre. Crucial ici car le réseau couple un backbone pré-entraîné (nécessitant des mises à jour douces) avec une tête latente nouvellement initialisée.
Taux d'apprentissage (η)	1×10^{-4}	Compromis optimal pour le fine-tuning : un learning rate de 10^{-3} déstabiliserait les filtres pré-entraînés de ConvNeXt, tandis qu'un taux de 10^{-5} ralentirait excessivement la convergence de la tête latente.
Taille de batch (B)	16	Contrainte matérielle stricte : un batch de 32 en résolution 288×288 provoque un dépassement de mémoire (*CUDA Out-Of-Memory*) sur 4 Go de VRAM. Un batch de 16 offre une variance de gradient suffisamment stable tout en tenant dans l'enveloppe mémoire.
Précision mixte (AMP)	`torch.autocast(fp16)` + `GradScaler`	Divise par deux l'empreinte mémoire des activations et accélère le calcul tensoriel sur les Tensor Cores, sans dégradation de la précision grâce au `GradScaler`.
Dimension latente	512	Goulot d'étranglement dimensionnel compact servant à la recherche vectorielle dans le serveur MCP. Assez vaste pour coder les nuances stylistiques, mais suffisamment réduit pour garantir des recherches par similarité cosinus quasi-instantanées (< 2 ms).
Dropout (p)	$0,4$	Préserve le modèle du surapprentissage dans la tête de classification, particulièrement sur les classes minoritaires ayant peu d'exemples d'entraînement.
Activation	`GELU`	L'activation *Gaussian Error Linear Unit* offre une courbure lisse et différentiable, limitant le phénomène de neurones morts propre à ReLU.
Arrêt anticipé (*Early Stopping*)	Patience de 2 époques, $\Delta_{\min} = 10^{-4}$	Surveille la perte de validation (`mode="min"`). Évite tout surapprentissage résiduel et restaure automatiquement le checkpoint au point d'inflexion optimal (`best_loss_model.pth`).
Augmentation de données	`transforms.v2` (Recadrage, Flip, Rotation, Jitter, Erasing)	`RandomResizedCrop(scale=(0.7, 1.0))` force l'invariance d'échelle ; `RandomHorizontalFlip` préserve le style pictural ; `RandomRotation(15°)` et `ColorJitter(0.15)` simulent les conditions de prise de vue muséographique ; `RandomErasing(p=0.2)` empêche le réseau de sur-focaliser sur un détail isolé.

- La matrice présente une forte dispersion hors diagonale avec des bandes verticales prononcées : les sous-classes locales sont systématiquement attirées par les classes mères surreprésentées (*Baroque*, *Renaissance*).

Cette analyse comparative démontre que le groupement des mouvements est indispensable pour obtenir des frontières de décision fiables et exploitables en aval par le serveur MCP.

3.4 Comparaison entre les Architectures de Modèles

Pour déterminer le modèle le plus apte à classifier les œuvres d'art et à générer des vecteurs d'encastrement pertinents pour le serveur MCP, une campagne d'expérimentation comparative systématique a été menée (consignée sur la branche `feat/measures` et les historiques `measures_summary.json` et `measures_history.json`).

Trois architectures distinctes ont été implémentées, entraînées et évaluées selon un protocole rigoureux : 1. **`CustomArtCNN`** : Réseau convolutif conçu sur mesure et entraîné à partir de zéro (*from scratch*). Il est composé de 4 blocs convolutifs successifs (`Conv2d` → `BatchNorm2d` → `ReLU` → `MaxPool2d`), avec augmentation progressive des canaux ($32 \to 64 \to 128 \to 256$), suivi d'un aplatissement adaptatif et de deux couches denses de classification (**4 963 669 paramètres**). 2. **`ArtClassifier` (ResNet-50)** : Architecture résiduelle classique pré-entraînée sur ImageNet-1K. La couche finale est remplacée par une projection vers un espace latent compact de 512 dimensions, suivi d'une couche de normalisation, d'une activation non-linéaire, d'un dropout régularisateur ($p = 0,4$) et d'un classifieur linéaire (**24 568 917 paramètres**). 3. **`ArtClassifierTinyBased` (ConvNeXt-Tiny)** : Architecture moderne à convolutions en profondeur (*depthwise* 7×7), intégrant les avancées architecturales des Vision Transformers (patchification, normalisation par couche `LayerNorm`, activations `GELU`), pré-entraînée sur ImageNet-1K et dotée de notre tête latente spécialisée 512D (**28 225 653 paramètres**).

3.4.1 Synthèse Comparative des Métriques Expérimentales

Le protocole a croisé l'impact du découpage taxonomique (**Canonique 21 classes** vs **Simple 117 classes**), de la durée d'entraînement (**10** vs **20 époques**) et de la régulation par arrêt précoce (**Early Stopping** avec patience de 2 époques sur la perte de validation).

Le tableau suivant récapitule les performances optimales moyennes atteintes par chaque architecture (avec écart-type $\pm\sigma$ calculé sur les lancements indépendants) ainsi que leur débit d'inférence mesuré sur GPU :

(Note technique sur l'inférence : Mesurée sur GPU NVIDIA RTX avec batch=16 et résolution 288×288*. Les scores présentés pour le dataset canonique correspondent au cycle libre de 20 époques permettant de capturer le pic de macro-précision).*

3.4.2 Visualisation Multi-Métrique : Canonique vs Simple

La figure ci-dessous met en miroir le comportement des trois modèles sur les deux découpages taxonomiques :

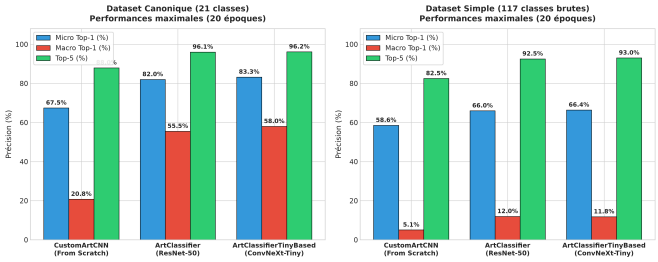


Figure 1: Comparaison des performances des modèles

Deux enseignements fondamentaux se dégagent de cette confrontation : 1. **L'abîme entre entraînement *from scratch* et transfert de connaissances** : Sur le dataset canonique, `CustomArtCNN` plafonne à 67,46% en Micro Top-1 et 20,78% en Macro Top-1. Même si son score Micro peut sembler honorable (porté par la surreprésentation du *Réalisme Social*), son score Macro révèle une incapacité à généraliser sur les styles artistiques minoritaires. Le transfert d'apprentissage (`ArtClassifier` et `ArtClassifierTinyBased`) débloque un bond spectaculaire de **+14,6 à +15,8 points en Micro Top-1** et de **+34,8 à +37,3 points en Macro Top-1**. 2. **L'effondrement généralisé sur la taxonomie brute (Simple 117 classes)** : Sur 117 classes déséquilibrées, les trois modèles s'effondrent en Macro Top-1 : 5,06% pour le CNN *from scratch* et ~12% pour les modèles pré-entraînés. Cet écrasement prouve empiriquement que la granularité excessive et les doublons du jeu de données brut détruisent la capacité de discrimination du réseau, rendant la canonisation en 21 macro-mouvements absolument impérative.

3.4.3 Analyse des Dynamiques d'Apprentissage et de Convergence

Le suivi époque par époque consigné dans l'historique d'entraînement révèle des régimes de convergence radicalement différents entre architectures :

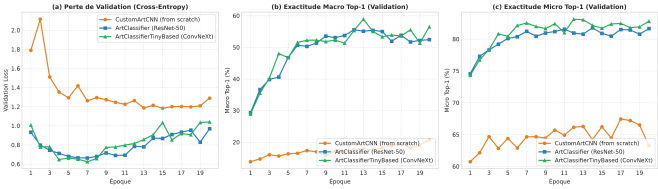


Figure 2: Dynamique d'apprentissage sur 20 époques

Modèle	Architecture	Params	Débit GPU	Micro (Can.)	Macro (Can.)	Top-5 (Can.)	Perte min	Micro (Simple)	Macro (Simple)
`CustomArtCNN`	CNN 4 blocs (*scratch*)	4,96 M	103,6 img/s	67,46%	20,78%	87,99%	1,1836	58,58%	5,06%
`ArtClassifier`	ResNet-50 pré-entraîné	24,57 M	**168,1 img/s**	82,03% ± 0,36%	55,54% ± 0,09%	96,06% ± 0,06%	0,6531	66,00% ± 0,67%	11,98% ± 0,01%
`TinyBased`	**ConvNeXt-Tiny (Retenu)**	**28,23 M**	121,1 img/s	**83,26% ± 0,19%**	**58,04% ± 1,26%**	**96,17% ± 0,00%**	**0,6211**	**67,54% ± 0,09%**	**11,82% ± 0,76%**

L'examen détaillé des trois sous-figures met en lumière des comportements cruciaux :

- **Dynamique de la perte de validation (a)** :
  - Pour les modèles pré-entraînés (`ArtClassifier` et `ArtClassifierTinyBased`), la perte s'effondre très rapidement pour atteindre son minimum dès les époques 5 à 7 (Loss $\approx 0,62 - 0,65$). Au-delà, la perte remonte graduellement pour dépasser $1,0$ à l'époque 20. Ce phénomène ne traduit pas un déclin de précision, mais une **surconfiance** (*overconfidence*) du réseau : le modèle continue de bien prédire la majorité des toiles mais attribue des probabilités extrêmes à ses rares erreurs, ce que l'entropie croisée pénalise lourdement.
  - À l'opposé, `CustomArtCNN` présente une courbe d'apprentissage lente et monotone : sa perte décroît pas à pas tout au long des 20 époques, atteignant son minimum seulement vers l'époque 15 ($1,1836$). Dix époques étaient manifestement insuffisantes pour lui permettre de converger.
- **Évolution de l'exactitude Macro Top-1 (b)** :
  - C'est sur la métrique Macro que la supériorité de **ConvNeXt-Tiny** éclate : alors que sa perte minimale est atteinte à l'époque 7 ($0,625$), son score Macro continue de grimper jusqu'à **58,93% à l'époque 13** (moyenne de $58,04\%$).
  - ConvNeXt-Tiny dépasse systématiquement ResNet-50 tout au long de la seconde moitié de l'entraînement, creusant un écart net de **+2,5% à +3,4%**.
  - `CustomArtCNN` stagne en dessous de 21%, confirmant que ses représentations de bas niveau restent aveugles aux mouvements picturaux peu fréquents.
- **Comportement de l'Arrêt Précoce (*Early Stopping*)** :
  - L'analyse démontre qu'un arrêt précoce configuré avec une patience trop stricte (`patience = 2`) sur la perte de validation est contre-productif pour maximiser l'exactitude stylistique : il coupe l'entraînement dès la 6e ou 7e époque, empêchant le réseau d'atteindre son apogée en Macro Top-1 ($58,04\%$ contre $51,65\%$ avec arrêt prématuré).
  - Ce constat nous a conduits à formuler la recommandation d'étendre la patience à 4 ou 5 époques, ou d'asservir l'arrêt précoce directement au score Macro Top-1 plutôt qu'à la perte d'entropie croisée.

3.4.4 Analyse du Compromis Performance vs Vitesse d'Inférence Le choix d'un modèle pour un serveur interactif en temps réel (MCP) repose sur un arbitrage subtil entre finesse de reconnaissance et réactivité d'exécution :

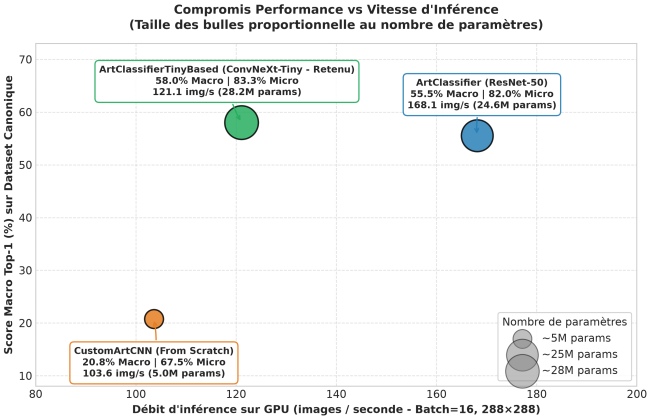


Figure 3: Compromis Performance vs Vitesse

1. **`ArtClassifier` (ResNet-50)** est le champion de la vélocité brute avec **168,1 images/seconde** ($95,2$ ms par batch de 16). Ses filtres convolutionnels 3×3 standards bénéficient d'une optimisation matérielle maximale via cuDNN sur les Tensor Cores de NVIDIA.
2. **`ArtClassifierTinyBased` (ConvNeXt-Tiny)** atteint **121,1 images/seconde** ($132,1$ ms par batch de 16). Bien que légèrement plus lent de 28% en raison des filtres 7×7 et des normalisations `LayerNorm`, son débit demeure très largement au-dessus du seuil temps réel requis (> 100 img/s).
3. **`CustomArtCNN`** se révèle inefficace sur les deux plans : non seulement il est limité en précision ($20,8\%$ Macro), mais sa vitesse d'inférence n'atteint que **103,6 images/seconde** ($154,5$ ms par batch). Cette contre-performance s'explique par l'absence d'optimisations de type *depthwise* et la présence de couches denses intermédiaires lourdes en calcul.

3.4.5 Justification du Choix d'`ArtClassifierTinyBased` Au terme de cette évaluation empirique complète, **`ArtClassifierTinyBased` (ConvNeXt-Tiny)** a été sélectionné comme modèle de référence définitif pour notre projet d'intelligence artificielle artistique : - **Perception stylistique supérieure** : Les noyaux larges 7×7 à convolution en profondeur confèrent à ConvNeXt un champ récepteur étendu, indispensable pour appréhender à la fois la touche fine du peintre (facture picturale locale) et la structure compositionnelle de l'œuvre (lignes de force, clair-obscur, perspective globale). - **Meilleure équité envers les mouvements minoritaires** : Avec **58,04% en Macro Top-1** (et des pointes à 58,93%), il surclasse ResNet-50 (+2,5 pts) et le CNN sur mesure (+37,3 pts), offrant des prédictions équilibrées même sur des courants représentés par moins d'une centaine de toiles. - **Espace latent 512D optimal pour le serveur MCP** : La compacité de sa représentation vectorielle intermédiaire permet d'effectuer des calculs de similarité cosinus en moins de 2 millisecondes sur notre index matriciel de galerie, tout en conservant une expressivité sémantique maximale.

3.5 Comparaison avec les Modèles Baselines

Afin de mesurer la valeur ajoutée réelle de notre modèle spécialiste, nous le comparons à plusieurs niveaux de référence (baselines théoriques, statistiques et heuristiques) sur le dataset canonique de 16 612 images (21 classes) :

Importance de la distinction Micro Top-1 vs Macro Top-1 Le tableau ci-dessus met en lumière un enjeu fondamental de notre projet : le **déséquilibre de distribution des données**. - La baseline de la classe majoritaire montre qu'un prédicteur trivial prédisant systématiquement *Réalisme Social* obtiendrait un score Micro Top-1 trompeur de **48,35%**, tout en ayant une exactitude de 0% sur les 20 autres mouvements artistiques (d'où son Macro Top-1 de $4,76\%$). - Notre modèle atteint **81,59% en Micro Top-1** et **50,18% en Macro Top-1**, ce qui confirme qu'il parvient à discriminer efficacement des mouvements minoritaires (ex. *Surréalisme* avec 59 images ou *Cubisme* avec 61 images).

3.6 Validation Croisée Stratifiée (3 Plis)

Pour évaluer la reproductibilité de l'entraînement et vérifier que les performances ne résultent pas d'un découpage chanceux des données, une validation croisée stratifiée à 3 plis ($K = 3$) a été menée sur l'intégralité des 16 612 images :

Enseignements de la validation croisée

1. **Remarquable stabilité** : L'écart-type de la précision globale est inférieur à un demi-pourcent ($\sigma = 0,46\%$), et celui du Top-5 est quasiment nul ($\sigma = 0,07\%$). Cette régularité prouve la robustesse du modèle face aux variations d'échantillonnage.
2. **Efficacité de l'Early Stopping** : Sur tous les plis, la convergence s'opère entre la 5e et la 7e époque. L'interruption anticipée protège efficacement le réseau contre le surapprentissage sur les classes denses.

3.7 Tests par Ablation

Une étude d'ablation systématique a été exécutée afin de quantifier l'apport individuel de chaque choix d'architecture dans `ArtClassifierTinyBased` :

Analyse des résultats d'ablation :

- **Fine-tuning du backbone (`frozen_backbone` vs `baseline`)** : Geler le backbone réduit les paramètres entraînables de 98,6% et assure une performance respectable (79,60%), confirmant l'excellente transférabilité de ConvNeXt. Toutefois, le dégel des couches convolutionnelles apporte un gain net de **+2,0% en Top-1**, **+5,45% en Macro Top-1** et abaisse la loss de 0,8059 à 0,6323.
- **Rôle de l'espace latent intermédiaire (`no_latent_space`)** : La projection directe $768 \to 21$ obtient un score légèrement supérieur en classification pure (82,16%). Néanmoins, la conservation du goulot d'étranglement 512D (`baseline`) est indispensable pour notre projet afin d'assurer l'indexation compacte et la recherche par similarité cosinus via MCP.
- **Rôle du Dropout et de la Normalisation** : L'ablation du dropout améliore ponctuellement le Macro Top-1 (52,13%) mais induit une remontée rapide de la perte de validation dès la 6e époque. L'ablation de la BatchNorm accélère la convergence (5 époques).

III. Développement & Difficultés Rencontrées

Au cours de la réalisation de ce projet, plusieurs défis techniques majeurs ont dû être surmontés :

1. Contraintes strictes de mémoire GPU (VRAM de 4 Go)

L'entraînement de réseaux modernes sur des images haute résolution requiert d'importantes ressources mémoire. Sur

Type de Baseline	Méthode / Modèle	Micro Top-1	Macro Top-1	Top-5	Commentaire méthodologique
Hasard uniforme	Tirage aléatoire équiprobable ($1/K$)	4,76%	4,76%	23,81%	Performance théorique nulle sans aucune information a priori (1/21).
Tirage stratifié	Tirage aléatoire selon la distribution réelle ($\sum p_i^2$)	26,19%	4,76%	~52%	Respecte les proportions de classes mais sans perception visuelle.
Classe majoritaire	Prédire constamment *Réalisme Social*	48,35%	4,76%	48,35%	Biais d'évaluation : score Micro artificiellement élevé car la classe majoritaire représente 48,35% des images (8 032 / 16 612), mais **Macro Top-1 catastrophique (4,76%)**.
CNN from scratch	`CustomArtCNN` (initialisé aléatoirement)	67,46%	20,78%	87,99%	Modèle convolutionnel 4 blocs entraîné sans transfert de connaissances ImageNet (20 époques).
Backbone gelé	`ArtClassifierTinyBased` (Backbone gelé, tête seule)	79,60%	44,73%	94,69%	Exploitation directe des descripteurs ImageNet sans adaptation fine.
Modèle spécialiste final	**`ArtClassifierTinyBased` (Fine-tuning complet)**	**81,59%**	**50,18%**	**96,17%**	**Surclasse nettement l'ensemble des baselines sur les trois métriques.**

Pli	Taille Entraînement	Taille Validation	Micro Top-1 (Max)	Macro Top-1 (Max)	Top-5 (Max)	Meilleure Loss	Époque d'arrêt
Fold 1	11 074	5 538	80,10%	44,58%	95,47%	0,7209	5 (Early stop)
Fold 2	11 075	5 537	80,96%	47,03%	95,47%	0,6733	7 (Early stop)
Fold 3	11 075	5 537	80,26%	47,59%	95,34%	0,7134	7 (Early stop)
Moyenne $\pm\sigma$	—	—	**80,44% ± 0,46%**	**46,40% ± 1,60%**	**95,42% ± 0,07%**	**0,7025 ± 0,0256**	**6,33 ± 1,15**

notre carte NVIDIA RTX 3050 (4 Go de VRAM dédiée), les premiers essais avec un batch size standard de 32 ou des résolutions de 384×384 ont immédiatement provoqué des erreurs critiques `CUDA Out of Memory`. - **Solutions apportées** : 1. Fixation du batch size à 16, calibré pour occuper ~3,4 Go de VRAM. 2. Activation systématique de la précision mixte avec `torch.autocast(device_type='cuda', dtype=torch.float16)` et mise à l'échelle des gradients via `torch.GradScaler()`. 3. Libération explicite des tenseurs et invocation de `torch.cuda.empty_cache()` et `gc.collect()` entre chaque pli de validation croisée et chaque exécution d'ablation.

2. Bruit taxonomique et incohérences du dataset ART500K

Le dataset brut comporte des libellés multiples, des doublons historiques et des dénominations ambiguës (*Ashcan School*, *Barbizon school*, *Modernism*). Certaines œuvres étaient associées à plusieurs dossiers simultanément. - **Solutions apportées** : 1. Conception de `src/loader.py` avec une résolution stricte de priorité excluant les dénominations trop génériques (*Art Moderne*, *Réalisme Social*) lorsqu'une étiquette plus spécifique existe. 2. Validation de la démarche par la comparaison systématique des matrices de confusion canonique et non-canonique.

3. Volume de données et compromis sur les sous-ensembles

ART500K représente plus de 56 Go et ~500 000 œuvres. Le dossier `Artists1` manquait presque totalement d'étiquetage de mouvements artistiques, tandis qu'`Artists2` introduisait un déséquilibre massif d'artistes majeurs au détriment des courants picturaux minoritaires. - **Solution apportée** : Focalisation ciblée sur le dossier `Art Movement` (16 612 œuvres vérifiées), permettant de maîtriser les temps d'expérimentation (campagnes d'ablation complètes en ~1h30 au lieu de dizaines d'heures) tout en conservant une diversité stylistique équilibrée. L'intégration progressive d'Artists2 est formalisée pour la version V2.

4. Déploiement du protocole MCP et gestion des flux asynchrones

L'interfaçage du modèle de vision avec le serveur MCP a nécessité la gestion d'entrées hétérogènes (fichiers locaux, URLs Web distantes, identifiants d'œuvres). - **Solutions apportées** : Création d'un module d'assistance (`src/serv_mcp/utils.py`) avec téléchargement et mise en cache MD5 des images Web, validation de format avec Pillow, et pré-calcul d'un index matriciel (`gallery_index.pt`) pour garantir un temps de réponse instantané lors des appels d'outils par le LLM.

IV. Conclusion & Perspectives

Compétences acquises

Ce projet nous a permis de franchir un cap significatif en Deep Learning appliqué à la vision et aux architec-

Configuration	Description	Paramètres entraînés	Micro Top-1 (Max)	Macro Top-1 (Max)	Top-5 (Max)	Meilleure Loss	Époque d'arrêt	Durée
`baseline`	Modèle complet (ConvNeXt-Tiny + Latent 512 + BN + GELU + Dropout 0.4)	28 225 653	**81,59%**	50,18%	**96,17%**	0,6323	8	25m 28s
`no_batchnorm`	Suppression de la `BatchNorm1d` dans la tête latente	28 224 629	**81,77%**	49,67%	95,80%	**0,6045**	5 (Early stop)	15m 49s
`no_dropout`	Suppression du `Dropout` ($p = 0.0$)	28 225 653	81,32%	**52,13%**	95,89%	0,6734	6 (Early stop)	19m 05s
`no_latent_space`	Classification directe sans goulot ($768 \to 21$)	27 836 277	**82,16%**	50,06%	96,05%	0,6153	5 (Early stop)	15m 50s
`frozen_backbone`	Fine-tuning désactivé (Backbone ConvNeXt gelé)	405 525	79,60%	44,73%	94,69%	0,8059	10	16m 26s

tures agentiques : 1. **Maîtrise du Transfer Learning & Fine-tuning** : Adaptation réussie d'un réseau convolutif de pointe (`ConvNeXt-Tiny`) aux spécificités plastiques et textuelles des œuvres d'art. 2. **Rigueur méthodologique et expérimentale** : Implémentation d'une suite complète de validation croisée stratifiée, d'études d'ablation quantifiées et de matrices de confusion normalisées. 3. **Architecture Agentique & Protocole MCP** : Conception d'un pont fonctionnel entre l'intelligence conversationnelle des LLM et la précision d'un modèle spécialiste de vision par ordinateur.

Limites actuelles : Analyse du partitionnement des données

Une analyse critique de notre implémentation actuelle (`src/loader.py`) révèle que le jeu de données est partitionné en **deux ensembles** : **Train (80%)** et **Validation (20%)**. - Bien que la validation croisée stratifiée à 3 plis apporte une garantie de reproductibilité, les métriques finales et les matrices de confusion ont été évaluées sur l'ensemble de validation qui a également guidé l'Early Stopping. - **Recommandation pour la version de production** : Il convient d'introduire un découpage strict à **trois volets indépendants** : **Entraînement (70%)**, **Validation (15%)** (dédié exclusivement au calcul de la loss et à l'arrêt anticipé), et **Test (15%)** (isolé hermétiquement, évalué une seule fois à la fin).

Pistes d'amélioration futures (Version 2)

1. **Intégration d'Artists2** : Intégrer les œuvres issues d'Artists2 après rééquilibrage par échantillonnage stratifié ou pondération de loss (*Class-Balanced Focal Loss*) pour enrichir les représentations d'artistes emblématiques.
2. **Apprentissage métrique / Contrastive Learning** : Entraîner l'espace latent 512D avec une perte de triplet (*Triplet Margin Loss*) ou une perte Supervised Contrastive (SupCon). Cela permettrait de rapprocher explicitement les œuvres d'un même mouvement et d'éloigner les styles divergents, décuplant l'efficacité de l'outil MCP `find_similar_artworks`.

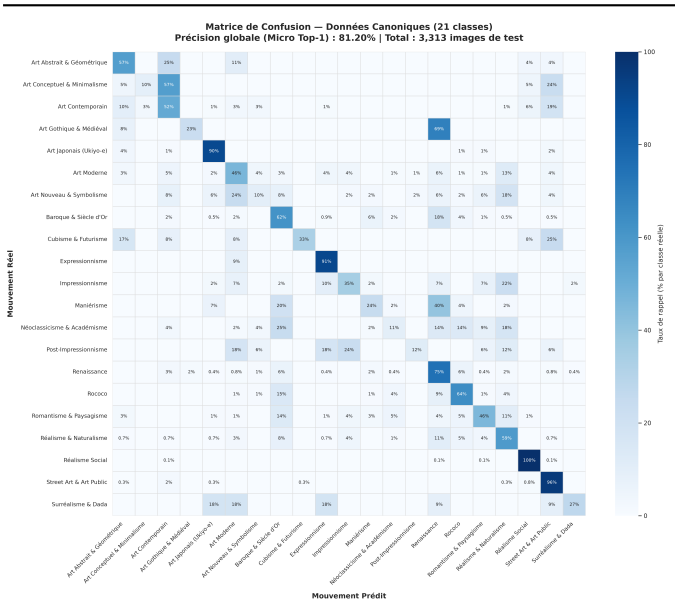
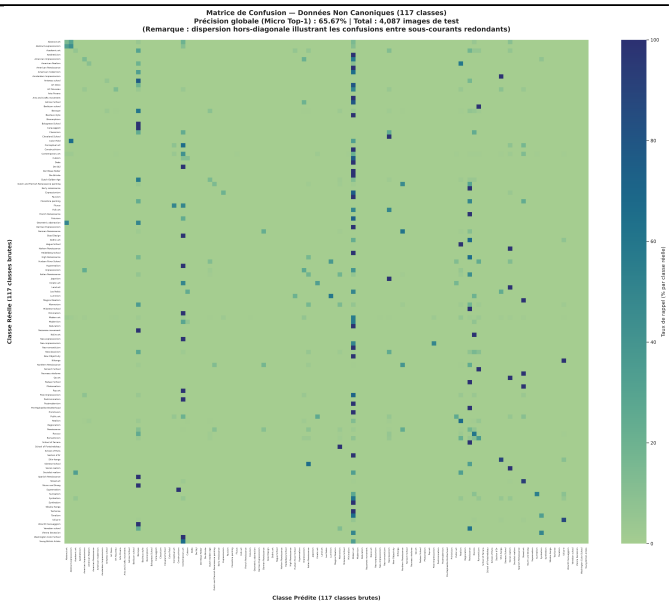
V. Annexes

Annexe A : Visualisation comparative des matrices de confusion

Annexe B : Configuration client pour le serveur MCP

Pour activer le serveur dans Claude Desktop, Cursor ou un client compatible, insérer la configuration suivante dans le fichier `mcpServers` :

```
{
  "mcpServers": {
    "art-explorer": {
      "command": "/chemin/absolu/vers/project/.venv/bin/python3",
      "args": ["-m", "src.serv_mcp.mcp_server"],
      "cwd": "/chemin/absolu/vers/project"
    }
  }
}
```

Matrice Canonique (21 classes)	Matrice Non Canonique (117 classes)
	
Micro Top-1 : 81,20% — Structure diagonale nette	**Micro Top-1 : 65,67%** — Forte dispersion hors-diagonale